

INTELIGÊNCIA ARTIFICIAL & DIREITO

TRIBUTÁRIO

Protótipo de Chatbot Jurídico baseado em LLM e RAG

Programas de Negociação de Dívidas Tributárias
(Programa Quita Goiás)

PESQUISADORES

- 👤 Augusto Camilo da Silva Neto
- 👤 Juliana Pereira de Souza Zinader
- 👤 Lucas Gonçalves da Silva

Contexto e Desafio



Complexidade Tributária

A legislação brasileira é extremamente densa e volátil. O **baixo letramento jurídico** da população dificulta a compreensão de direitos e deveres fiscais.



Gargalo no Atendimento

A alta demanda por informações especializadas sobre dívidas fiscais **sobrecarrega os órgãos públicos**, gerando filas e demora nas respostas.



Limitação das IAs Comuns

Modelos de linguagem puros (LLMs) podem gerar "**alucinações**" (respostas plausíveis, porém falsas), o que é inaceitável no contexto do Direito.



A Solução Proposta (RAG)

Retrieval-Augmented Generation: Unindo busca documental e geração de texto

Fluxo de Dados




1. Consulta

Pergunta do Cidadão



2. Recuperação

Busca em Leis e Editais



3. Re-ranking

Refinamento Semântico



4. Geração

LLM + Contexto



5. Resposta

Fundamentada e Citada



Ancoragem Real

Todas as respostas são baseadas estritamente nos documentos oficiais recuperados, evitando invenções.



Rastreabilidade

O sistema indica exatamente qual artigo de lei ou cláusula do edital fundamentou a resposta.



Segurança Jurídica

Redução drástica de "alucinações", garantindo que o cidadão receba orientações corretas.

Objetivo do Estudo



Objetivo Geral

Desenvolver e avaliar um **chatbot inteligente** capaz de ampliar o acesso e a precisão das informações sobre negociação de dívidas tributárias.



Foco Prático

Apoiar a comunicação direta entre o **Estado de Goiás** e o contribuinte, focando no contexto do Programa Quita Goiás.



Metas de Qualidade

Assegurar precisão nas respostas, total **rastreabilidade** das fontes legais e um tempo de resposta inferior a **10 segundos**.



Metodologia de Desenvolvimento

Abordagem híbrida combinando rigor científico e agilidade técnica



Abordagem de Pesquisa



Pesquisa Aplicada

Estudo exploratório conduzido em ambiente controlado, focado na resolução de problemas práticos do setor público.



Dataset Curado

Base de conhecimento construída exclusivamente com fontes oficiais: leis complementares, portarias e manuais da PGE-GO.



Ciclos Iterativos

Desenvolvimento em espiral, com avaliações constantes de desempenho para refinamento dos prompts e parâmetros.



Engenharia & Validação



Vibe Coding

Fluxo de desenvolvimento moderno orientado à intenção e linguagem natural, acelerando a prototipagem.



Human-in-the-loop

Curadoria humana crítica em todas as etapas: desde a geração do código até a validação das respostas da IA.



Auditoria Especializada

Revisão manual dos diálogos para garantir conformidade jurídica e ausência de alucinações críticas.

Arquitetura do Sistema

Pipeline de RAG em dois estágios com orquestração via LangGraph

Pipeline de Processamento



Entrada

Pergunta do Usuário



Estágio 1

Recuperação Híbrida



Estágio 2

Re-ranking (Cross-Encoder)



Orquestração

LangGraph + Contexto



Geração

Google Gemini



Recuperação Híbrida

Busca vetorial por similaridade semântica com o uso de embeddings. Foram usados chunks semânticos e chunks de tamanho fixo.



Re-ranking Semântico

O Cross-Encoder reordena os documentos recuperados comparando-os diretamente com a pergunta, priorizando o contexto mais relevante e descartando ruído.



LLM & Orquestração

Google Gemini gera a resposta final baseada estritamente nos documentos filtrados. O fluxo é controlado pelo LangGraph para robustez.

Base de Dados e Amostra

Fundamentação legal e estratégia de testes do protótipo



Fontes Oficiais (Base de conhecimento)



Legislação Base

Lei Complementar nº 197/2024, que institui as regras fundamentais do programa de negociação.



Regulamentação Específica

Portarias e Editais do programa **Quita Goiás**, definindo prazos, descontos e condições.



Manuais Técnicos

Orientações internas e manuais da Procuradoria-Geral do Estado de Goiás (PGE-GO).



Amostra de Teste (n=59)



50 Perguntas Sintéticas

Cenários criados para testar limites do sistema, incluindo "casos de borda" (edge cases) e situações típicas de dúvida.



9 Perguntas Reais

Casos extraídos diretamente de atendimentos verídicos realizados nos órgãos públicos, garantindo validação com a realidade.

59

TOTAL DE INTERAÇÕES AVALIADAS

Resultados: Motor de Recuperação

Análise Comparativa de Eficiência: Pódio de Performance de 3 Estratégias

MELHOR RESULTADO

Dados da estratégia Híbrida + Re-ranking



1º LUGAR
Híbrida + Re-ranking

MELHOR



2º LUGAR
Reranked Chunk Fixo



ÚLTIMO LUGAR
Busca Vetorial Semântica

HIT RATE (ACERTO)

80%

● Alta precisão



MRR (RANKING)

0.71

★ Relevância no topo



PRECISION@1

66%

📌 1ª resposta correta

1



INSIGHT CRÍTICO: QUALIDADE DO RANKING

Embora o **Chunk Fixo** tenha alcançado o mesmo **Hit Rate de 80%** que a estratégia vencedora, seu **MRR inferior (0.64 vs 0.71)** revela que ele posiciona documentos relevantes mais abaixo na lista. A estratégia **Híbrida** coloca a resposta correta no topo com mais frequência, o que é crucial para evitar alucinações.

Resultados: Ciclo Completo (Chatbot)

Taxas de Aprovação (Feedback Humano) e Performance Temporal

PERGUNTAS SINTÉTICAS

80%

✍ Casos de borda e testes



PERGUNTAS REAIS

87.5%

✓ atendimentos públicos




LATÊNCIA TOTAL

< 10s

⚡ Recuperação ~1.1s



Taxa de Aprovação por Tipo de Pergunta



Eficiência em Cenários Reais

Surpreendentemente, o desempenho com **perguntas reais (87.5%)** superou os testes sintéticos. Isso valida a capacidade do modelo RAG de lidar com a complexidade e a linguagem natural dos contribuintes, mantendo um tempo de resposta ágil para o serviço público.

Garantia de Qualidade e Auditoria

Processos de controle, validação humana e rastreabilidade da IA



Monitoramento Contínuo

Registro integral de todas as sessões e interações. O sistema detecta anomalias e padrões de uso em tempo real.



QA Suite (Human-in-the-Loop)

Interface dedicada para especialistas jurídicos revisarem diálogos, validarem respostas e corrigirem a IA.



Logs e Rastreabilidade

Trilha de auditoria completa: *Qual documento foi usado? Qual trecho? Quando foi a consulta?*



Atualização Controlada

Versionamento da base legal. A IA só acessa documentos homologados, evitando uso de leis revogadas.



A arquitetura foi desenhada para priorizar a segurança jurídica sobre a criatividade, garantindo que o chatbot atue como um assistente confiável do Estado.

audit_trail.log

```
2026-02-08 14:00:01 [INFO] Session initialized
(ID: 59a-2)
2026-02-08 14:00:02 [USER] "Como aderir ao Quita
Goiás?"
2026-02-08 14:00:03 [RAG] Retrieving docs ...
>> Doc Found: Lei_Comp_197_2024.pdf
>> Relevance Score: 0.89
>> Chunk ID: #442 (Art. 3º)
2026-02-08 14:00:04 [LLM] Generating response
anchored in #442
2026-02-08 14:00:05 [AUDIT] Response logged.
2026-02-08 14:05:12 [QA_TOOL] Flagged for review:
false
...
// Auditoria completa garantida
```

STATUS: ONLINE

SECURE CONTEXT

Conclusões



Viabilidade Técnica

O protótipo provou-se tecnicamente **sólido e seguro** para aplicação no domínio jurídico-tributário, garantindo a integridade das informações prestadas.



Impacto Operacional

Houve redução significativa de alucinações da IA, demonstrando potencial para **aliviar a sobrecarga** do atendimento humano especializado.



Contribuição Pública

Apresentamos um modelo **replicável e auditável**, estabelecendo um padrão para o uso responsável de IA na gestão pública.

Próximos Passos

► Perspectivas Futuras



Testes com Usuários Finais

Realizar avaliações de usabilidade com cidadãos reais (contribuintes) para validar a clareza da linguagem jurídica simplificada.



Investigação de Fine-Tuning

Treinar modelos menores com dados específicos do estado para reduzir custos computacionais e latência.



Expansão do Escopo

Adaptar a arquitetura RAG para outros programas de negociação fiscal e diferentes entes federativos.

Acesso ao Código-Fonte

```
// Clone o repositório do projeto
```

```
$ github.com/AugustoCamilo/UFG-ESP-T2-NLP-G25
```

● Python ● LangChain ● Gemini



Obrigado!

Estamos abertos para dúvidas.