

INTELIGÊNCIA ARTIFICIAL & DIREITO

TRIBUTÁRIO

Protótipo de Chatbot Jurídico baseado em LLM e RAG

Programas de Negociação de Dívidas Tributárias
(Programa Quita Goiás)

PESQUISADORES

- 👤 Augusto Camilo da Silva Neto
- 👤 Juliana Pereira de Souza Zinader
- 👤 Lucas Gonçalves da Silva

1

🚩 Introdução

- Contexto e Desafio
- A Solução Proposta (RAG)
- Objetivo do Estudo

2

🧪 Metodologia

- Abordagem da Pesquisa
- Engenharia & Validação
- Arquitetura do Sistema
- Base de Dados e Amostra

3

📝 Resultados e Discussão

- Motor de Recuperação
- Ciclo Completo (Chatbot)
- Garantia de Qualidade e Auditoria

4

💡 Conclusões

- Próximos Passos

5

📖 Referências

- Bibliografia Consultada

Contexto e Desafio



Complexidade Tributária

A legislação brasileira é extremamente densa e volátil. O **baixo letramento jurídico** da população dificulta a compreensão de direitos e deveres fiscais.



Gargalo no Atendimento

A alta demanda por informações especializadas sobre dívidas fiscais **sobrecarrega os órgãos públicos**, gerando filas e demora nas respostas.



Limitação das IAs Comuns

Modelos de linguagem puros (LLMs) podem gerar "**alucinações**" (respostas plausíveis, porém falsas), o que é inaceitável no contexto do Direito.



A Solução Proposta (RAG)

Retrieval-Augmented Generation: Unindo busca documental e geração de texto

Fluxo de Dados



1. Consulta

Pergunta do Cidadão



2. Recuperação

Busca em Leis e Editais



3. Re-ranking

Refinamento Semântico



4. Geração

LLM + Contexto



5. Resposta

Fundamentada e Citada



Ancoragem Real

Todas as respostas são baseadas estritamente nos documentos oficiais recuperados, evitando invenções.



Rastreabilidade

O sistema indica exatamente qual artigo de lei ou cláusula do edital fundamentou a resposta.



Segurança Jurídica

Redução drástica de "alucinações", garantindo que o cidadão receba orientações corretas.

Objetivo do Estudo



Objetivo Geral

Desenvolver e avaliar um **chatbot inteligente** capaz de ampliar o acesso e a precisão das informações sobre negociação de dívidas tributárias.



Foco Prático

Apoiar a comunicação direta entre o **Estado de Goiás** e o contribuinte, focando no contexto do Programa Quita Goiás.



Metas de Qualidade

Assegurar precisão nas respostas, total **rastreabilidade** das fontes legais e um tempo de resposta inferior a **10 segundos**.



Metodologia de Desenvolvimento

Abordagem híbrida combinando rigor científico e agilidade técnica



Abordagem de Pesquisa



Pesquisa Aplicada

Estudo exploratório conduzido em ambiente controlado, focado na resolução de problemas práticos do setor público.



Dataset Curado

Base de conhecimento construída exclusivamente com fontes oficiais: leis complementares, portarias e manuais da PGE-GO.



Ciclos Iterativos

Desenvolvimento em espiral, com avaliações constantes de desempenho para refinamento dos prompts e parâmetros.



Engenharia & Validação



Vibe Coding

Fluxo de desenvolvimento moderno orientado à intenção e linguagem natural, acelerando a prototipagem.



Human-in-the-loop

Curadoria humana crítica em todas as etapas: desde a geração do código até a validação das respostas da IA.



Auditoria Especializada

Revisão manual dos diálogos para garantir conformidade jurídica e ausência de alucinações críticas.

Arquitetura do Sistema

Pipeline de RAG em dois estágios com orquestração via LangGraph



Recuperação Híbrida

Busca vetorial por similaridade semântica com o uso de embeddings. Foram usados chunks semânticos e chunks de tamanho fixo.



Re-ranking Semântico

O Cross-Encoder reordena os documentos recuperados comparando-os diretamente com a pergunta, priorizando o contexto mais relevante e descartando ruído.



LLM & Orquestração

Google Gemini gera a resposta final baseada estritamente nos documentos filtrados. O fluxo é controlado pelo LangGraph para robustez.

Base de Dados e Amostra

Fundamentação legal e estratégia de testes do protótipo



Fontes Oficiais (Base de conhecimento)



Legislação Base

Lei Complementar nº 197/2024, que institui as regras fundamentais do programa de negociação.



Regulamentação Específica

Portarias e Editais do programa **Quita Goiás**, definindo prazos, descontos e condições.



Manuais Técnicos

Orientações internas e manuais da Procuradoria-Geral do Estado de Goiás (PGE-GO).



Amostra de Teste (n=59)



50 Perguntas Sintéticas

Cenários criados para testar limites do sistema, incluindo "casos de borda" (edge cases) e situações típicas de dúvida.



9 Perguntas Reais

Casos extraídos diretamente de atendimentos verídicos realizados nos órgãos públicos, garantindo validação com a realidade.

59

TOTAL DE INTERAÇÕES AVALIADAS

Resultados: Motor de Recuperação

Análise Comparativa de Eficiência: Pódio de Performance de 3 Estratégias

🏆 MELHOR RESULTADO

Dados da estratégia Híbrida + Re-ranking

HIT RATE (ACERTO)

80%

🟢 Alta precisão

MRR (RANKING)

0.71

★ Relevância no topo

PRECISION@1

66%

📌 1ª resposta correta



1º LUGAR
Híbrida + Re-ranking

MELHOR



2º LUGAR
Reranked Chunk Fixo



ÚLTIMO LUGAR
Busca Vetorial Semântica



INSIGHT CRÍTICO: QUALIDADE DO RANKING

Embora o **Chunk Fixo** tenha alcançado o mesmo **Hit Rate de 80%** que a estratégia vencedora, seu **MRR inferior (0.64 vs 0.71)** revela que ele posiciona documentos relevantes mais abaixo na lista. A estratégia **Híbrida** coloca a resposta correta no topo com mais frequência, o que é crucial para evitar alucinações.

Resultados: Ciclo Completo (Chatbot)

Taxas de Aprovação (Feedback Humano) e Performance Temporal

PERGUNTAS SINTÉTICAS



80%

✍ Casos de borda e testes

PERGUNTAS REAIS



87.5%

✓ atendimentos públicos


LATÊNCIA TOTAL



< 10s

⚡ Recuperação ~1.1s

Taxa de Aprovação por Tipo de Pergunta



Eficiência em Cenários Reais

Surpreendentemente, o desempenho com **perguntas reais (87.5%)** superou os testes sintéticos. Isso valida a capacidade do modelo RAG de lidar com a complexidade e a linguagem natural dos contribuintes, mantendo um tempo de resposta ágil para o serviço público.

Garantia de Qualidade e Auditoria

Processos de controle, validação humana e rastreabilidade da IA



Monitoramento Contínuo

Registro integral de todas as sessões e interações. O sistema detecta anomalias e padrões de uso em tempo real.



QA Suite (Human-in-the-Loop)

Interface dedicada para especialistas jurídicos revisarem diálogos, validarem respostas e corrigirem a IA.



Logs e Rastreabilidade

Trilha de auditoria completa: *Qual documento foi usado? Qual trecho? Quando foi a consulta?*



Atualização Controlada

Versionamento da base legal. A IA só acessa documentos homologados, evitando uso de leis revogadas.



A arquitetura foi desenhada para priorizar a segurança jurídica sobre a criatividade, garantindo que o chatbot atue como um assistente confiável do Estado.

```
audit_trail.log

2026-02-08 14:00:01 [INFO] Session initialized
(ID: 59a-2)
2026-02-08 14:00:02 [USER] "Como aderir ao Quita
Goiás?"
2026-02-08 14:00:03 [RAG] Retrieving docs ...
>> Doc Found: Lei_Comp_197_2024.pdf
>> Relevance Score: 0.89
>> Chunk ID: #442 (Art. 3º)
2026-02-08 14:00:04 [LLM] Generating response
anchored in #442
2026-02-08 14:00:05 [AUDIT] Response logged.
2026-02-08 14:05:12 [QA_TOOL] Flagged for review:
false
...
// Auditoria completa garantida
```

STATUS: ONLINE

SECURE CONTEXT

Ferramenta de Validação do Banco de Vetores (Chunks)

Interface de auditoria para teste de busca vetorial e re-ranking semântico


01. Execução



Configuração do Teste

Interface inicial exibindo o menu lateral completo com opções de validação e a área de execução de busca.


02. Resultados



Recuperação de Chunks

Exibição dos chunks recuperados com seus respectivos *Scores de Relevância*, permitindo análise imediata da precisão do retriever.

03. Avaliação




Feedback Humano (QA)

Módulo de avaliação onde o especialista valida quais resultados estão corretos e seleciona a "melhor resposta" para cálculo de MRR.


Ferramenta de Auditoria (Validação Chunks)

Painel administrativo para análise de métricas, filtragem de sessões e inspeção detalhada




Dashboard de Performance

Resumo consolidado dos KPIs (Hit Rate, MRR, Precisão) segmentado por tipo de estratégia de busca, exibindo menu lateral completo.



Filtragem de Sessões

Listagem interativa de avaliações com filtros avançados para identificar casos de baixa performance e analisar outliers.



Inspeção Profunda

Visualização granular dos chunks retornados e das perguntas associadas, permitindo auditar a qualidade textual.

Auditoria do Histórico do Chatbot RAG

Interface de auditoria para análise de feedbacks e estatísticas de uso


01. Resumo



Painel de Feedbacks

Interface centralizada que permite a visualização e filtragem de todos os feedbacks recebidos. Inclui opções de busca por sessão e exportação de dados (CSV/XML) para auditoria externa.

02. Visualização



Métricas de Satisfação

Dashboard analítico apresentando a tabela de performance com tempos de resposta e gráfico de distribuição de avaliações, evidenciando 80% de feedbacks positivos (Likes) nos testes sintéticos.

Programa Quita Goiás

Interface do assistente virtual para negociação de dívidas tributárias



Controle da Aplicação

Tela de configuração inicial exibindo o menu lateral com opções de origem da pergunta (Usuário Real vs. Teste Sintético) e gerenciamento do ciclo de vida da sessão.




Fluxo de Atendimento

Exemplo de resposta gerada via RAG: o sistema explica o programa Quita Goiás, detalhando benefícios e descontos com base na Lei Complementar nº 197/2024. A interface exibe também os botões de feedback (Like/Dislike) ao final da resposta.


Auditoria do Chatbot: Histórico e Validação

Ferramentas avançadas para análise de conversas e consistência das respostas



Histórico do Chat

Exemplo da lista de históricos de conversa com o chatbot, apresentando a avaliação e o tipo da conversa, se teste sintético ou conversa real. Esta interface permite filtrar sessões, visualizar feedbacks (likes/dislikes) e exportar dados para análise externa.



Validação Cruzada

O sistema faz um cruzamento com as validações dos chunks e mostra o resultado da validação dos chunks para cruzar os resultados. O sistema pesquisa na validação usada para o chatbot, garantindo que a resposta gerada esteja alinhada com os documentos de referência previamente auditados (Score 1.0000).

Conclusões



Viabilidade Técnica

O protótipo provou-se tecnicamente **sólido e seguro** para aplicação no domínio jurídico-tributário, garantindo a integridade das informações prestadas.



Impacto Operacional

Houve redução significativa de alucinações da IA, demonstrando potencial para **aliviar a sobrecarga** do atendimento humano especializado.



Contribuição Pública

Apresentamos um modelo **replicável e auditável**, estabelecendo um padrão para o uso responsável de IA na gestão pública.

Próximos Passos

► Perspectivas Futuras



Testes com Usuários Finais

Realizar avaliações de usabilidade com cidadãos reais (contribuintes) para validar a clareza da linguagem jurídica simplificada.



Investigação de Fine-Tuning

Treinar modelos menores com dados específicos do estado para reduzir custos computacionais e latência.



Expansão do Escopo

Adaptar a arquitetura RAG para outros programas de negociação fiscal e diferentes entes federativos.



Recursos Técnicos

Acesse o protótipo e documentação completa



Acesso ao Código-Fonte

```
// Clone o repositório do projeto
```

```
$ github.com/AugustoCamilo/UFG-ESP-T2-NLP-G25
```



Python



LangChain



Gemini

Referências

- **BARDIN, Laurence.** *Análise de conteúdo*. São Paulo: Edições 70, 2011.

- **BRASIL.** *Lei nº 13.709, de 14 de agosto de 2018*. Dispõe sobre a proteção de dados pessoais e altera a Lei nº 12.965, de 23 de abril de 2014 (Lei Geral de Proteção de Dados Pessoais – LGPD). Diário Oficial da União: seção 1, Brasília, DF, 15 ago. 2018.
Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 17 jan. 2026.

- **BROWN, Tom et al.** Language models are few-shot learners. *Advances in Neural Information Processing Systems*, v. 33, p. 1877–1901, 2020.
Disponível em: <https://papers.nips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>. Acesso em: 17 jan. 2026.

- **CAMILO.** *UFG-ESP-T2-NLP-G25: código-fonte do protótipo de chatbot de recuperação híbrida*. 2026.
Disponível em: <https://github.com/AugustoCamilo/UFG-ESP-T2-NLP-G25.git>. Acesso em: 26 jan. 2026.

- **CRESWELL, John W.** *Research design: qualitative, quantitative, and mixed methods approaches*. 4. ed. Thousand Oaks: Sage Publications, 2014.

- **FENG, Yifan et al.** Legal dialogue systems based on retrieval-augmented generation. *Artificial Intelligence and Law*, v. 31, p. 451–472, 2023.
Disponível em: <https://link.springer.com/article/10.1007/s10506-023-09355-1>. Acesso em: 17 jan. 2026.

Obrigado!



Estamos abertos para perguntas e discussões

EQUIPE DE PESQUISA



**Augusto Camilo
da Silva Neto**

Pesquisador



**Juliana Pereira
de Souza Zinader**

Pesquisadora



**Lucas Gonçalves
da Silva**

Pesquisador